1.实验内容：

对美国国会投票案例进行关联规则挖掘

1.数据来源：http://archive.ics.uci.edu/ml/datasets/Congressional+Voting+Records

2.使用 Apriori 算法，支持度设为 30%，置信度为 90%，挖掘高置信度的规则。

2.分析及设计：

1.数据集中投票的来源有两类人，一类是共和党人，另一类是民主党人。数据集中的投票一共有三种表现形式：赞成（y），反对（n）和弃权（?）。由于弃权占了实验中的数据集的少数，因此在本次实验中我并没有去对弃权的票进行关联规则分析。因此选定了以下四种关联规则挖掘方式：

(1).对身份是共和党+投赞成票进行关联规则分析，选出哪些事件之间可能存在关联。

(2).对身份是共和党+投反对票进行关联规则分析，选出哪些事件之间可能存在关联。

(3).对身份是民主党+投赞成票进行关联规则分析，选出哪些事件之间可能存在关联。

(4).对身份是民主党+投反对票进行关联规则分析，选出哪些事件之间可能存在关联。

2.首先了解 Apriori 算法的原理：

Apriori 是一种常用的数据关联规则挖掘方法，它可以用来找出数据集中频繁出现的数据集合。找出这样的一些频繁集合有利于决策，例如通过找出超市购物车数据的频繁项集，可以更好地设计货架的摆放。需要注意的是它是一种**逐层迭代**的方法，先找出频繁 1 项集 L1，再利用 L1 找出频繁 2 项集，以此类推……

3.在使用 Apriori 算法进行设计时，需要考虑剪枝，及时排除掉支持度不足的规则，这样可以很有效地提升程序的性能。

3.详细实现：

对数据进行归类统计代码实现如下：（代码中附带注释）

```python
import pandas as pd

mydata=pd.read_csv('/home/anqian/Test2/house-votes-84.data', sep=',', header=None)
#使用mydata进行投票结果的统计
republican_ycount=[]
republican_ncount=[]
republican_wcount=[]
democrat_ncount=[]
democrat_ycount=[]
democrat_wcount=[]
for i in range(16):
    republican_ycount.append(0)
    republican_ncount.append(0)
    republican_wcount.append(0)
    democrat_ycount.append(0)
    democrat_ncount.append(0)
    democrat_wcount.append(0)
    for j in range (435):
        if mydata[0][j] == 'republican':
            if mydata[i+1][j]=='y':
                republican_ycount[i]+=1
            elif mydata[i+1][j]=='?':
                republican_wcount[i]+=1
            else:
                republican_ncount[i]+=1
        else:
            if mydata[i+1][j]=='y':
                democrat_ycount[i]+=1
            elif mydata[i+1][j] == '?':
                democrat_wcount[i]+=1
            else:
                democrat_ncount[i]+=1

#输出投票统计的结果
print('republican_y:',republican_ycount)
print('republican_n:',republican_ncount)
print('republican_w:',republican_wcount)
print('democrat_y:',democrat_ycount)
print('democrat_n:',democrat_ncount)
print('democrat_w:',democrat_wcount)
```

Apriori 算法的实现：

```python
def mining(data, dic_before, suport, coincidence):
  dic_3 = {}
  #对二阶遍历输出的字典进行挖掘
  for item0 in dic_before:
    for item1 in dic_before:
      if (item0 != item1):
        # print(item0,item1)
        item_len = len(item0)
        equal = True
        tmp_item3 = []
        # 判断前n-1项是否一致
        for i in range(item_len - 1):
          tmp_item3.append(item0[i])
          if (item0[i] != item1[i]):
            equal = False
            break
        if (equal == True):
          minitem = min(item0[-1], item1[-1])
          maxitem = max(item0[-1], item1[-1])
          tmp_item3.append(miniten)
          tmp_item3.append(maxiten)
          tmp_item3 = tuple(tmp_item3)
          dic_3[tmp_item3] = 0
        else:
          continue
  # print('dic_3:',dic_3)
  #剪枝
  for data_line in data:
    for item in dic_3:
      is_in = True
      for i in range(len(item)):
        if (item[i] not in data_line):
          is_in = False

      if (is_in == True):
        dic_3[item] += 1

  #计算数据规模，用于计算支持度和置信度
  count = len(data)
  dic_3n = {}

  for item in dic_3:
    count_item0 = dic_before[item[:-1]]
    # 判断 支持度 和 置信度
    if ((dic_3[item] >= suport * count) and (dic_3[item] >= coincidence * count_item0)):
      dic_3n[item] = dic_3[item]

  return dic_3n
```

需要注意的是：Apriori 算法更深层次关联规则的挖掘基于对关联规则进行初步的挖掘，代码如下：

```python
def mining_first(data, suport, coincidence):
    #挖掘候选1-项集
    dic = {}
    count = len(data)
    for data_line in data:
        for data_item in data_line:
            if(data_item in dic):
                dic[data_item] += 1
            else:
                dic[data_item] = 1

    item_suport = int(count * suport)
    dic_1 = {}
    for item in dic:
        if(dic[item] >= item_suport):
            dic_1[item] = dic[item]

    return dic_1

def mining_second(data, dic_before, suport, coincidence):
    #挖掘出候选2-项集
    dic = {}
    count = len(data)
    count2 = 0
    for data_line in data:
        for i in range(len(data_line)):
            for j in range(i + 1, len(data_line)):
                if(data_line[i] in dic_before and data_line[j] in dic_before):
                    count2 += 1
                    tmp = (data_line[i], data_line[j])
                    if(tmp in dic):
                        dic[tmp] += 1
                    else:
                        dic[tmp] = 1
                else:
                    continue

    dic_2 = {}
    for item in dic:
        count_item0 = dic_before[item[0]]
        count_item1 = dic_before[item[1]]
        # 判断支持度和置信度
        if((dic[item] >= suport * count) and ((dic[item] >= coincidence * count_item0) or (dic[item] >= coincidence * count_item1))):
            dic_2[item] = dic[item]

    return dic_2
```

4.实验结果：

输出结果如图所示：

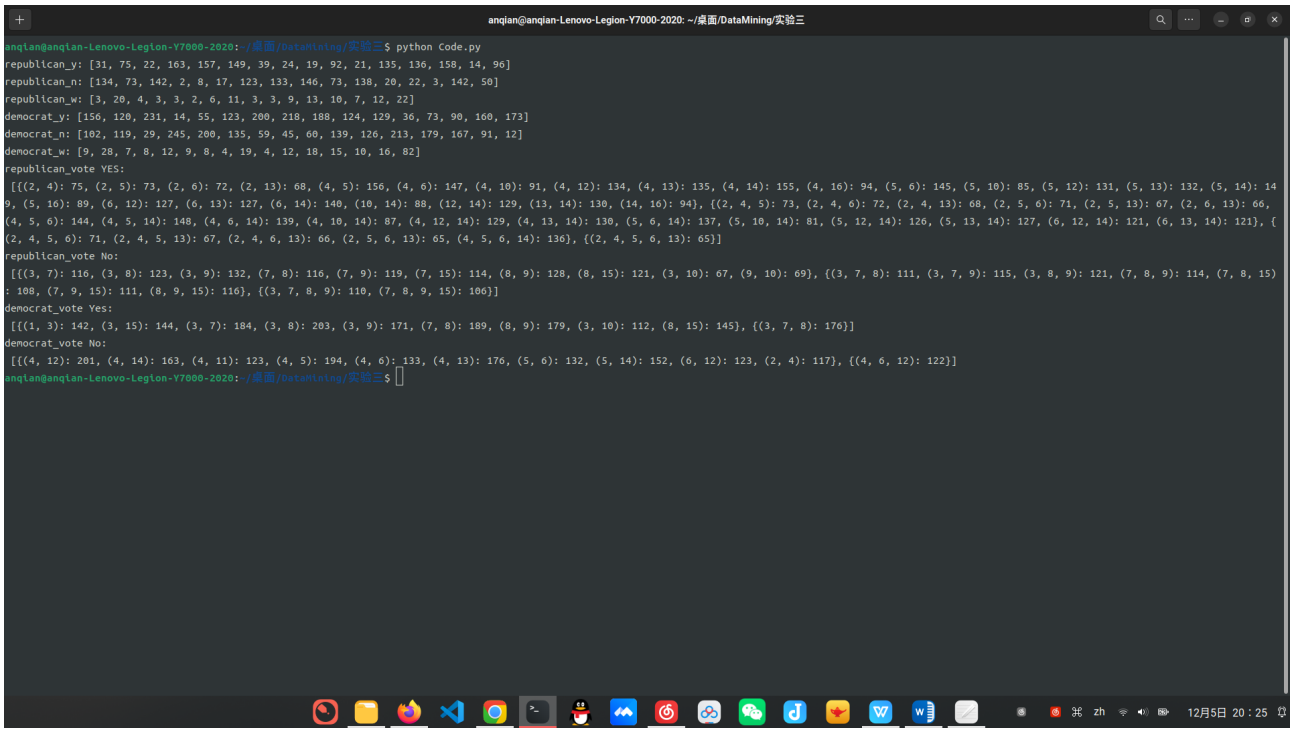

上半部分的输出结果表示对结果统计的输出。

下半部分输出结果表示挖掘出的关联规则，以最下面一行的 democrat_vote No 为例，(4,12) 表示第四个事件与第 12 个事件具有关联，换言之，民主党对“通过预算的决议”（事件 4）投了反对票，往往也会对“合成燃料公司削减”（事件 12） 投反对票。
输出的实验结果不是很符合预期，比如 republic_vote Yes 部分，有很多具有包含关系的频繁项集，在输出之前其实可以进行一些合并操作，但是由于最近各学科都很忙碌，进行数据挖掘的实验时间不是很充分，因此没有足够的时间去研究代码了，所以留有一些漏洞。

5.心得体会:

本次实验比较相比于上两次实验还是要复杂一些的，因为前两次实验可以自己选择调用 Python 的包，而本次实验只能选择自己实现，因此花的时间要比较多，通过对 Apriori 算法的实现，自己也是对该算法更加了解了，虽然没有实现的比较好，但是也算是一个初步的进展吧。

数据挖掘的实验就此完结了，在此谈一下总的感受吧。总体来说实验是真的帮助自己学到了很多的实用的知识，比如实验一可以用类似的模型来训练自己想要分类的事物，把实验模型运用到生活中来，只要有充足的数据支持，训练的模型会更加的精确。自己对数据挖掘/机器学习的认识也有了一个比较完整的轮廓，如果想要提升自己的能力，需要做的可能就是更多的实践了。